

데이터 분석 입문반

한 기 영

(주)데이터인사이트 대표

강사 소개 - 한기영



- ✓ 2000 ~ 2015 년
 - 이랜드에서 15년간, Data엔지니어, 데이터분석 팀장, 패션부문 IT 책임자
- ✓ 2016년 ~ 현재
 - 데이터 분석 회사를 설립하고
 - 데이터분석, 인공지능 강의 및 컨설팅을 하고 있습니다.
- ✓ 강의 경력
 - 현, KT 에이블스쿨 1~7기, 메인 강사
 - SK, LG, 롯데, 포스코, GS 등 대기업 IT회사의 데이터분석 및 AI 직무 교육
 - 경희대, 이화여대, 성균관대 등에서 데이터분석 인공지능 강의
- ✓ 프로젝트 경력
 - M사 비정상계약 고객 사전 예측
 - S사, 패션 고객 추천 시스템 설계
 - D사, 제강라인 불량 예측
 - H사, 수요량 예측 프로젝트

사전설문 https://bit.ly/bdai_0904_1



[데이터 분석 입문반(ML)]

- ✓ 수업 시간 : 목 21:00~22:00, 16회 차
- ✓ 개요 :
 - 데이터 분석의 표준 절차인 **CRISP-DM**을 기반으로
 - 기초 프로그래밍부터 **통계 분석, 시각화, 머신러닝 모델링**까지 단계적으로 학습합니다.
 - 이론과 예제를 적절히 배치하고, **추가 실습 자료** 제공합니다.
- ✓ 과정이 끝나면 여러분은...
 - **데이터 분석 전 과정**을 이해하고 적용할 수 있다.
 - 통계 분석을 통해 **데이터를 분석하고 비즈니스 관점에서 해석**할 수 있다.
 - **기본적인 머신러닝 모델링** 기법을 활용하여 예측 모델을 구축하고 성능을 평가할 수 있다.
- ✓ 선수 지식 : 파이썬 기초, 판다스 데이터프레임 기본 지식



[데이터 분석 입문반(ML)]

차시	주제	세부 내용
1	데이터분석 표준 프로세스(CRISP-DM)	- 절차 : 비즈니스 이해 > 데이터 이해 > 데이터 준비 > 모델링 > 평가 > 배포 - 문제 정의
2	파이썬 및 판다스 복습	- 파이썬 기본 자료형, 리스트, 딕셔너리 - 판다스 데이터프레임, 시리즈 - 함수
3	데이터 시각화 기초	matplotlib, seaborn 그래프 그리기 기초
4	단변량 분석1 - 수치형	- 기초 통계량 : 평균, 사분위수, 최소, 최대 - 시각화 : 히스토그램, kde plot(밀도함수 그래프), 박스 플롯
5	단변량 분석2 - 범주형	- 기초 통계량 : 범주별 빈도수, 비율 - 시각화 : 막대 그래프
6	이변량 분석1 - 수치형 vs 수치형	- 가설검정 : 상관분석 - 시각화 : 산점도
7	이변량 분석2 - 범주형 vs 수치형	- 가설검정 : t-검정, 분산분석 - 시각화 : 평균비교 막대그래프
8	이변량 분석3 - 범주형 vs 범주형	- 가설검정 : 카이제곱검정 - 시각화 : 모자익플롯



차시	주제	세부 내용
9	이변량 분석4 - 수치형 vs 범주형	- 가설검정 : $X \rightarrow y$ - 시각화 : 히스토그램, kde plot
10	데이터 전처리1 - 결측치 조치, 가변수화	- 모델링을 위한 데이터 요건 - 결측치 조회 및 조치 방법 - 가변수화
11	데이터 전처리2 - 스케일링, 데이터 분할	- 스케일링 : 정규화, 표준화 - train, validation, test 분할 및 역할
12	머신러닝 모델링 개요	- 지도학습, 비지도학습, 강화학습 - 회귀, 분류 - 모델링 무작정 따라하기
13	회귀 모델링	- 기본 알고리즘 : 선형회귀 - 회귀 모델 평가
14	분류 모델링	- 기본 알고리즘 : 로지스틱회귀 - 분류 모델 평가
15	기본 알고리즘	- tree 기반 알고리즘 : 의사결정 나무 - 거리 기반 알고리즘 : KNN
16	Review	총 복습

[데이터 분석 입문반(ML)]

✓ 개발 환경 : 구글 Colab

✓ 매 회차별 강의 자료 제공

- 교안 pdf
- 코드파일 ipynb
 - 코드파일 안에 복습 문제 제공



몇 가지 당부 사항

✓ 질문은

- (QnA)오픈 채팅방을 활용해주세요.
- 수업 시간에 질문을 받기가 어렵습니다. 하지만, 수업 마지막 즈음에 질문 한 두개 받는 시간을 갖겠습니다.

✓ 수업시간 반응은 활발히!

- 활발히 반응하다 보면 집중도 잘된답니다.
- 과도한 반응은 강사를 힘내게 합니다!

1. 데이터분석 표준 프로세스 (CRISP-DM)


전체 Process(CRISP-DM)

★ 무엇이 문제인가?

- ✓ 비즈니스 문제정의
- ✓ 데이터분석 방향, 목표
- ✓ 초기 가설 수립

$x \rightarrow y$

- ✓ 모델 관리
- ✓ AI 서비스 구축



- ✓ 원본식별
- ✓ 분석을 위한 구조 만들기
- ✓ 데이터분석 EDA & CDA

- ✓ 모델링을 위한 데이터 구조 만들기
 - 모든 셀은 값이 있어야 한다.
 - 모든 값은 숫자 여야 한다.
 - (필요 시) 숫자의 범위가 일치

- ✓ 모델을 만들고
- ✓ 검증하기

★ 문제가 해결 되었는가?

- ✓ 기술적 관점 평가
- ✓ 비즈니스 관점 평가

① Business Understanding - 가설 수립


✓ 문제를 정의하고 요인을 파악하기 위해서 가설을 수립합니다.

✓ 과학 연구에서는

- 기존 연구 결과로 이어져 내려오는 정설을 [귀무가설] 이라고 부르고
- 기존의 입장을 넘어서기 위한 새로운 연구 가설을 [대립가설] 이라고 부릅니다.
- 여기서 우리가 수립하는 가설을 대립가설로 부르기도 합니다.

✓ 가설 수립 절차


- ① 해결해야 할 문제가 무엇인가? (목표, 관심사, y)
- ② Y 를 설명하기 위한 요인을 찾아라. (x)
- ③ 가설의 구조를 정의하라. ($x \rightarrow y$)



② Data Understanding

✓ 데이터 원본 식별 및 취득

- (초기)가설에서 도출된 데이터의 원본을 확인




② Data Understanding

✓ 정리된 2차원 구조의 데이터셋을 분석하는 방법

① Exploratory Data Analysis 탐색적 데이터 분석

② Confirmatory Data Analysis 확증적 데이터 분석



✓ 우리는 다음의 사항을 알아야 합니다.

- ① (언제, 어떤) 그래프를 그리고 (어떻게) 해석
- ② (언제, 어떤) 통계량을 구하고 (어떻게) 해석
- ③ (언제, 어떤) 가설검정 방법을 사용하고 (어떻게) 해석

② Data Understanding

✓ 다음의 순서로 EDA 및 CDA를 진행합니다.

- ① 단변량 분석 : 개별 변수의 분포
 - 예 : 타이타닉 탑승객의 나이 분석
- ② 이변량 분석1 : feature와 target 간의 관계 (가설을 확인하는 단계)
 - 예 : 객실등급 → 생존여부 (객실등급에 따라 생존여부에 차이가 있나?)
- ③ 이변량 분석2 : feature들 간의 관계

PassengerId	Survived	Pclass	Name	Sex	Age	Fare	Embarked
1	0	3	Braund, Mr. Owen Harris	male	22.0	7.2500	Southampton
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	71.2833	Cherbourg
3	1	3	Heikkinen, Miss. Laina	female	26.0	7.9250	Southampton
4	1	1	Futelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	53.1000	Southampton
5	0	3	Allen, Mr. William Henry	male	35.0	8.0500	Southampton

② Data Understanding

✓ 데이터 탐색 : EDA, CDA

- 데이터를 탐색하는 두 가지 방법

통계량	시각화
분할표(Contingency Table) MIN, MAX, SUM, MEAN Quartile ...	Histogram, Box plot, Density plot Bar plot, Pie chart Scatter plot ...

- EDA (Exploratory Data Analysis)
 - - 개별 데이터의 분포, 가설이 맞는지 파악
 - - NA, 이상치 파악
- CDA (Confirmatory Data Analysis)
 - - 탐색으로 파악하기 애매한 정보는 통계적 분석 도구(가설 검정) 사용

③ Data Preparation

✓ 개요

- ① 모든 셀에 값이 있어야 한다.
- ② 모든 값은 숫자이어야 한다.
- ③ (옵션) 값의 범위를 일치시켜야 한다.

✓ 수행되는 내용

- 결측치 조치
- 가변수화
- 스케일링
- 데이터 분할

④ Modeling

✓ 개요

- 중요 변수들을 선택하고, 적절한 알고리즘을 적용하여 예측 모델을 생성
- 생성된 모델을 평가

✓ 수행되는 내용

- 중요 변수 선정
- 모델 생성
- 모델 성능 검증

④ Modeling

✓ 모델링(학습, Learning, Training)

- 데이터로부터 패턴을 찾는 과정.
- 오차를 최소화 하는 패턴
- 결과물 : 모델(모델은 수학적식으로 표현됨!)

✓ 모델링을 위해 필요한 두가지

- ① 학습 데이터
- ② 알고리즘

⑤ Evaluation

✓ 개요

- 모델에 대한 데이터 분석 목표와 비즈니스 목표달성에 대한 평가
- 모델과 데이터에서 추출한 패턴이 진정한 규칙성을 갖고 있는지, 단지 특정 예제 데이터에서만 볼 수 있는 특이한 성질은 아닌지 확인
- 비즈니스 목표에 부합되는지 보장

✓ 수행되는 내용

- 모델에 대한 최종평가: Test Set 이용
- 비즈니스 기대가치 평가

⑥ Deployment

✓ 개요

- 프로젝트 결과물 최종 확정: 프로덕션 환경의 파이프라인, 모델 및 배포가 고객 목표를 충족하는지 확인
- 운영시스템에서 품질(성능 목표) 유지 기준을 정하고, 모니터링 계획을 수립

✓ 수행되는 내용

- 시스템 유효성 검사: 배포된 모델과 고객 요구 사항을 충족 하는지 확인
- 프로젝트 이전 : 운영환경으로 배포
- 데이터 수집부터 모델 배포 관리까지 파이프라인으로 구성해야 함!


전체 Process(CRISP-DM) : Review

무엇이 문제인가?

- ✓ 비즈니스 문제정의
- ✓ 데이터분석 방향, 목표
- ✓ 초기 가설 수립

$x \rightarrow y$

- ✓ 모델 관리
- ✓ AI 서비스 구축



- ✓ 원본식별
- ✓ 분석을 위한 구조 만들기
- ✓ 데이터분석 EDA & CDA


- ✓ 모델링을 위한 데이터 구조 만들기
 - 모든 셀은 값이 있어야 한다.
 - 모든 값은 숫자 여야 한다.
 - (필요 시) 숫자의 범위가 일치

- ✓ 모델을 만들고
- ✓ 검증하기

문제가 해결 되었는가?

- ✓ 기술적 관점 평가
- ✓ 비즈니스 관점 평가

분석할 수 있는 데이터 구조



분석할 수 있는 데이터 구조

✓ 기본이 2차원

- Table, 2차원 Array, DataFrame

Target, y, Output,
Label, (종속변수)

① 열, 정보, 변수, 요인

Feature, X, input, (독립변수)

② 행,
분석단위,
샘플,
관측치,
Data point

Label	V01	V02	V03	V04	...	V##

분석할 수 있는 데이터 구조



NumPy

1D Array

3	2
---	---

2D Array

1	0	1
3	4	1

3D Array

1	7	9
5	9	3
7	9	9

수치 연산



pandas

	Name	Code-Name	Age	Weight in kgs
0	Amar	Alpha	23	69
1	Barsha	Bravo	25	54
2	Carlos	Charlie	22	73
3	Tanmay	Tango	27	70
4	Misbah	Mike	29	74

비즈니스 데이터 표현

추가 : Google Colab 설치


다음 시간까지 설치해 오세요~!

설치 절차

✓ 구글 ID가 있어야 합니다.

✓ 구글 드라이브로 로그인

- 구글 드라이브 화면 왼쪽 위 [+신규] 버튼 클릭
- 아랫부분 [더보기] > [+ 연결 앱 더보기] 클릭



- ✓ 검색 창에 'col'이라고만 입력하면 'colaboratory'가 뜹니다. 선택
- ✓ 제일 첫번째로 나오는 [Colaboratory] 클릭하고, [설치].

