

데이터 분석 입문반


한 기 영

(주)데이터인사이트 대표

4. 단변량 분석 수치형

숫자형 변수 - 어떻게 분석할 수 있을까요?

✓ 아래 20명의 나이 데이터(정보)가 있습니다.




데이터를 한눈에 파악하기 위해서
무엇을 해야 할까요?



숫자형 변수 - 정리하는 두가지 방법

① 숫자로 요약하기: 정보의 대푯값

- 평균(mean)
- 중앙값(median)
- 최빈값(mode)
- 사분위수(Quantile)




기초 통계량

② 구간을 나누고 빈도수(frequency) 계산

구간	빈도수
10대	?
20대	?
30대	?
40대	?

빈도수표



도수분포표
(frequency table)

숫자로 요약하기 : 정보의 대푯값

✓ 평균(mean)

- 산술 평균 $\checkmark$
- 기하 평균 $\times$
- 조화 평균 $\checkmark$

✓ 중위수(median) $\rightarrow$ 중앙값

- 자료의 순서상 가운데 위치한 값

✓ 최빈값(mode)

- 자료 중에서 가장 빈번한 값

Python Code

```
# 넘파이 함수 이용하기
np.mean(titanic['Fare'])

# 판다스의 mean 메서드 이용하기
titanic['Fare'].mean()
```

Python Code

```
# 넘파이 함수 이용하기
np.median(titanic['Fare'])

# 판다스의 median 메서드 이용하기
titanic['Fare'].median()
```

Python Code

```
# 판다스의 mode 메서드 이용하기
titanic['Pclass'].mode()
```


숫자로 요약하기 : 정보의 대푯값

✓ 평균(mean)을 대푯값으로 사용할 때 주의할 점

✓ 예 : 도서관 회원과 대출 분석

- 회원의 평균 나이 23.5 세.
- 회원들은 어떤 사람들일까요?


대학생



숫자로 요약하기 : 사분위수

✓ 사분위수

- 데이터를 오름차순으로 정렬한 후,
- 전체를 4등분하고, 각 경계에 해당되는 값(25%, 50%, 75%) 을 의미



✓ 다음의 숫자형 자료에 대해서 4분위수를 구해 봅시다.

1, 2, 3, 3, 4, 4, 4, 5, 6, 7, 8, 9, 10, 11, 15, 17, 18, 18, 19, 20, 25, 30

숫자로 요약하기: 기초 통계량

✓ 기초 통계량

- 숫자 몇 개로 분포를 요약

✓ df.describe()

■ 기초 통계량

- count: 데이터 개수.
 - Age의 개수가 다른 변수에 비해 적은 것은 NaN이 존재하기 때문
- 사분위수
 - 25%: 1사분위수
 - 50%: 2사분위수
 - 75%: 3사분위수

Python Code

```
titanic.describe()
```

Result

	PassengerId	Survived	Pclass	Age	Fare
count	891.000000	891.000000	891.000000	714.000000	891.000000
mean	446.000000	0.383838	2.308642	<u>29.699118</u>	32.204208
std	257.353842	0.486592	0.836071	14.526497	49.693429
min	1.000000	0.000000	1.000000	0.420000	0.000000
25%	223.500000	0.000000	2.000000	<u>20.125000</u>	7.910400
50%	446.000000	0.000000	3.000000	<u>28.000000</u>	14.454200
75%	668.500000	1.000000	3.000000	<u>38.000000</u>	31.000000
max	891.000000	1.000000	3.000000	80.000000	512.329200

사분위수

숫자나 범주에 따라 분석 방법이 달라진다.

--	--	--	--

↳ 시리즈

데이터 프레임 ['이름'].

describe

↳ 숫자 형태의 통계량을 나타냄

정
보
(
수치


★ titanic ['fare']

↳ 이렇게 작성함



숫자형 변수 시각화하기

✓ 숫자형 데이터를 정리하는 두가지 방법으로 부터 시각화

기초 통계량
(basic statistics)



도수분포표
(frequency table)



비슷한 정보 제공


숫자형 변수 시각화하기 - Histogram

✓ Histogram을 직접 손으로 그려봅시다.

- 1000점 만점인 시험에 110명이 응시한 결과입니다.

Score	Frequency
0-199	5
200-399	29
400-599	56
600-799	17
800-999	3

= count, 개수, 빈도수



숫자형 변수 시각화하기 - Histogram

✓ 문법

sns.histplot(x = 변수명, data = data, bins = 구간 수)

- edgecolor: bar의 윤곽선을 회색으로 표시

✓ 해석①

- 타이타닉호 탑승객의 운임(Fare)의 꼬리가 오른쪽으로
으로 상당히 치우친 분포 *꼬리가 어디로 늘려왔는지*
- 대부분의 탑승객은 \$30 이내
- 극 소수의 사람들이 \$200 이상


✓ 해석② *↪ 무의미한 내용 분석*

- 1910년대의 \$1는 현재의 약 1~200배 가치를 가지고 있다고 함.
- 탑승객 대부분은 중산층. 아메리칸 드림을 꿈꾸며 전 재산을 들고
미국으로 직업을 찾아 이주하려는 사람들.

Python Code

```
plt.hist(titanic.Fare, bins = 30  
         , edgecolor = 'gray')  
plt.xlabel('Fare')  
plt.ylabel('Frequency')  
plt.show()
```





Graph



숫자형 변수 시각화하기 - Histogram

✓ 히스토그램을 그릴 때, 주의 할 점 : bins를 적절히 조절

- 구간 ^{= 8개}의 개수에 따라서 파악할 수 있는 내용이 달라짐.



그래프 읽기

✓ 축의 의미 파악


- X축?, y축?

✓ 값의 분포로부터 파악할 내용

- 희박한 구간? 밀집 구간?
- 왜 그 구간은 희박한가? (밀집되어 있는가?)
→ 이에 대한 비즈니스 의미 파악

✓ 우리의 자세

- “엇? 왜 그렇지?”



그래프 읽기

✓ 축의 의미 파악


- X축?, y축?

✓ 값의 분포로부터 파악할 내용

- 희박한 구간? 밀집 구간?
- 왜 그 구간은 희박한가?(밀집되어 있는가?)
→ 이에 대한 비즈니스 의미 파악

✓ 우리의 자세

- “엇? 왜 그렇지?”



숫자형 변수 시각화하기 - Density Plot (KDE Plot)

✓ 히스토그램의 단점

- 구간(bin)의 너비에 따라 모양이 달라짐.

✓ 밀도함수 그래프

- 구간의 너비를 정하지 않아도 됨.
- 데이터의 밀도 추정
(Kernel Density Estimation)
- 밀도함수 그래프 아래 면적은 '1'
- 면적으로 구간에 대한 확률 추정


✓ 문법

- `sns.kdeplot(변수명)`

Python Code

```
sns.kdeplot(titanic['Fare'])  
plt.show()
```

Graph




숫자형 변수 시각화하기 - Box Plot


✓ plt.boxplot()

- 사전에 반드시 NaN을 제외(sns.boxplot은 NaN을 알아서 제거해 줌)
- vert 옵션 : 횡(False), 종(True, 기본값)

```
plt.boxplot(temp['Age'])  
plt.grid()  
plt.show()
```




```
plt.boxplot(temp['Age'], vert = False)  
plt.grid()  
plt.show()
```




숫자형 변수 시각화하기 – Box Plot

✓ 두 부분 : 박스 & 수염




숫자형 변수 시각화하기 – Box Plot

✓ 박스 : 4분위수



숫자형 변수 시각화하기 – Box Plot


✓ 박스 : 4분위수



숫자형 변수 시각화하기 – Box Plot

✓ IQR Inter Quartile Range

- 3사분위수 – 1사분위수




숫자형 변수 시각화하기 – Box Plot

- Actual Whisker Length : $1.5 * IQR$ 범위 이내의 최소, 최대값으로 결정
- Potential Whisker Length : $1.5 * IQR$ 범위, 잠재적 수염의 길이 범위

1.5인 이유

⇒ 이상치를 판별

2σ 바깥쪽을 이상치



과제 설명 →

→ 데이터 분석의 의미

→ 주제 작성할 것