

데이터 분석 입문반

한 기 영

(주)데이터인사이트

10. 머신러닝 모델링 개요


전체 Process(CRISP-DM)

무엇이 문제인가?

- ✓ 비즈니스 문제정의
- ✓ 데이터분석 방향, 목표
- ✓ 초기 가설 수립

$$x \rightarrow y$$

- ✓ 모델 관리
- ✓ AI 서비스 구축



- ✓ 원본식별
- ✓ 분석을 위한 구조 만들기
- ✓ 데이터분석 EDA & CDA

- ✓ 모델링을 위한 데이터 구조 만들기
 - 모든 셀은 값이 있어야 한다.
 - 모든 값은 숫자 여야 한다.
 - (필요 시) 숫자의 범위가 일치

- ✓ 모델을 만들고
- ✓ 검증하기

문제가 해결 되었는가?

- ✓ 기술적 관점 평가
- ✓ 비즈니스 관점 평가

모델, 모델링


✓ Model

- 모델 : 데이터로부터 **패턴**을 찾아, 수학적식으로 정리해 놓은 것
- 모델링 : 가능한한 **오차**가 적은 모델을 만드는 과정

✓ 모델의 목적


- 샘플을 가지고 전체를 추정
 - 샘플 : 표본, 부분집합, 일부, 과거의 데이터(우리가 들고 있는 데이터!)
 - 전체 : 모집단, 전체집합, 현재와 미래의 데이터
 - 추정 : 예측, 추론

AI? ML? DL?



Since an early flush of optimism in the 1950s, smaller subsets of artificial intelligence – first machine learning, then deep learning, a subset of machine learning – have created ever larger disruptions.

MACHINE LEARNING



지도 학습 Supervised Learning

Feature

Label

Model



고양이



개



고양이




개




?

비지도 학습 Unsupervised Learning

Label 없는 data



Model





강화 학습 Reinforcement Learning

✓ 특정 상태(state)에서 어떤 행동(action)을 취하는 것이 최적인지 학습

✓ 예 : 마리오 게임 학습

- Agent : 마리오(학습 대상)
- Environment : Agent가 상호작용하는 외부 세계
- State : Agent가 현재 있는 위치나 상황
- Action : Agent가 Environment에서 취할 수 있는 행동
- Reward : Agent가 어떤 Action을 취했을 때 Environment 으로부터 받는 피드백(보상)
- Policy : Agent가 어떤 State에서 어떤 Action을 취할지 결정하는 전략
 - 마리오가 어떤 State에서 점프할지, 걸을 지 등을 결정하는 규칙
 - 마리오가 반복 학습하면서 최적의 행동을 선택하는 과정을 통해 형성




패턴을 찾는 두가지 방법

정답이 있는 문제

지도학습(Supervised Learning)

- 답을 알려주면서 패턴을 찾게 하기




Supervised Learning

정답이 없는 문제

비지도학습(Unsupervised Learning)

- 데이터 안에서, 알아서 패턴 찾기
- 비슷한 데이터끼리 모아서




Unsupervised Learning

정답의 두가지 종류


- 숫자 - Regression
- 범주 - Classification

답의 두가지 종류 : Regression vs Classification

Regression
얼마나 많이?



Classification
A일까? B일까?



답의 두가지 종류 : Regression vs Classification

- ✓ 다음달에 약정기간이 끝나는 고객이 타 통신사로 이동할까?
- ✓ 이 타이어를 1000km안에 교체해야 할까?
- ✓ 내일 주가는 얼마일까?
- ✓ 내일 주가는 오를까?
- ✓ 더 많은 고객을 끌어들이기 위해서 5000원 쿠폰과 25%할인 중 무엇이 더 효과적일까?
- ✓ 이 제품의 다음주 수요량은?

머신러닝 코드 구조

데이터 전처리

불필요한 변수 제거

NaN 조치

데이터 분할1 : X, y

가변수화

데이터 분할2 : train, val

스케일링

모델링

모델 선언

학습

예측 및 검증 평가