

데이터 분석 입문반

한 기 영

(주)데이터인사이트

11. 데이터 전처리


전체 Process(CRISP-DM)

무엇이 문제인가?

- ✓ 비즈니스 문제정의
- ✓ 데이터분석 방향, 목표
- ✓ 초기 가설 수립

$$x \rightarrow y$$

- ✓ 모델 관리
- ✓ AI 서비스 구축



- ✓ 원본식별
- ✓ 분석을 위한 구조 만들기
- ✓ 데이터분석 EDA & CDA

- ✓ 모델링을 위한 데이터 구조 만들기
 - 모든 셀은 값이 있어야 한다.
 - 모든 값은 숫자 여야 한다.
 - (필요 시) 숫자의 범위가 일치

- ✓ 모델을 만들고
- ✓ 검증하기

문제가 해결 되었는가?

- ✓ 기술적 관점 평가
- ✓ 비즈니스 관점 평가

머신러닝 코드 구조

데이터 전처리

불필요한 변수 제거

NaN 조치

데이터 분할1 : X, y

가변수화

데이터 분할2 : train, val

스케일링

모델링

모델 선언

학습


예측 및 검증 평가

데이터 전처리

✓데이터 전처리에는 두가지 단계가 있습니다.

① 데이터 구조 만들기

② 모델링을 위한 전처리



모델링을 위한 데이터 전처리

✓ 모델링을 위한 (최소한의) 데이터 전처리 3가지 요건

- ① 모든 셀에 값이 있어야 한다.
- ② 모든 값은 숫자이어야 한다.
- ③ (옵션) 값의 범위를 일치시켜야 한다.

아하! 그래서...

- ① 결측치(NaN) 조치
 - ② 범주를 숫자로 변환하는 가변수화
 - ③ 범위를 일치시키는 스케일링
- ...을 배우는 것이군요!



데이터 전처리 : 데이터 분할 1 - x, y

변수

y : Target, Label,

X: Features, 요인

[illegible]

데이터 전처리 : 데이터 분할 2 - train, validation, test

	y	X					
	Label	V01	V02	V03	V04	...	V##
train							
	y_train			X_train			
validation							
	y_val			X_val			
test							
	y_test			X_test			

데이터 전처리 : train, validation, test 역할

✓ 데이터를 보통 Train, Test 로 나눕니다.

- **Train : 학습용**

- 모델을 생성할 때 사용. (예: 교재)

- **Validation : 검증용**

- 모델의 성능을 검증하는데 사용. (예 : 연습문제)

- **Test : 평가용**

- 모델의 성능을 평가하기 위한 용도 (예: 시험)

Train

Validation

Test

결측치(NaN)

✓NA(Not Available) 혹은 NaN(Not A Number)

- 사용할 수 없는 값
- 잘못 들어간 값
- 빈 값

✓NA조치 하는 방법

- ① 제거한다.
- ② 채운다.

결측치 제거

1) 결측치가 있는 열 제거



y	x01	x02	x03	x04
1	@@@	2	.45	AAA
0	###	3	.9	XXX
1	&&&	6	0	BBB
0	%%%	23	NaN	AAA
1	!!!	2	.75	AAA
0	NaN	32	.21	XXX

2) 결측치가 있는 행 제거



결측치 채우기

✓ 특정 값으로 채우기

- `.fillna()`
- 상수, 평균
- 이전/이후 값, 선형 보간법

✓ 추정해서 채우기

- `knnimputer()`
- 예측해서 적절한 값을 채우기.

가변수화

✓ 범주 → 숫자 : 가변수화

- 데이터는 머신러닝 알고리즘에 사용하려면 숫자로 변환해야 함
- One-Hot-Encoding
- `get_dummies()` 함수

Gender	
Male	
Female	
Male	
Female	



Male	Female
1	0
0	1
1	0
0	1

rank	
3	
1	
4	
2	





1	2	3	4
0	0	1	0
1	0	0	0
0	0	0	1
0	1	0	0

스케일링(Scaling)

✓ 거리 계산 알고리즘 : KNN, SVM, K-means

- 변수의 중요도와 상관 없이, 범위가 큰 변수가 거리에 영향을 많이 미침.
- 그래서 값의 범위를 맞춰 줄 필요가 있다.



스케일링(Scaling)

✓ 방법 1 : Normalization(정규화)

- 모든 값의 범위를 0 ~ 1로 변환
- 입력변수 X가 [a, b] 범위라면(a=min, b=max)

$$X_{norm} = \frac{x - a}{b - a}$$

✓ 방법2 : Standardization(표준화)

- 모든 값을, 평균 = 0, 표준편차 = 1 로 변환
- 이상치(outlier)가 많이 존재할 때 주로 사용

$$X_z = \frac{x - mean}{std}$$

요약 | Summary

✓ 데이터 전처리

- 모델링을 위해서는 특별한 데이터 구조를 준비해야 합니다.
 - ① 모든 셀에 값이 있어야 한다. → **NaN 조치**
 - ② 모든 값은 숫자이어야 한다. → **가변수화**
 - ③ (옵션) 값의 범위를 일치시켜야 한다. → **스케일링**

✓ 데이터 분할

- x, y 분할
- train : validation : test
 - train : 학습용
 - validation : 만든 모델에 대한 객관적(일반화) 성능 검증
 - test : 최종 테스트