

데이터 분석 입문반

한 기 영

(주)데이터인사이트

13주차_지도학습
기본 알고리즘1 -
선형회귀

선형 회귀

✓ 단순회귀(Simple Regression)

- 하나의 Feature로 하나의 Target을 예측

원소 $\rightarrow$ 마.판


✓ 다중회귀(Multiple Regression)

- 복수의 Feature로 하나의 Target을 예측

Linear Regression (선형회귀)

✓ 데이터를 하나의 직선으로 요약

- 자료를 설명하는 직선은 여러 개가 될 수 있습니다.
- 그 중 가장 잘 설명하는(전체 오차가 가장 적은) 직선 한 개를 선정하는 방법
 - 해석적(계산적) 방법 : 최소 제곱 법(Least Square)
 - 최적화 방법 : 오차를 조금씩 줄여가며 반복적으로 직선을 찾음(경사 하강법)



모델학습

$$y = w_1 \cdot x$$

$$= w_1 \cdot x_1 + w_2 \cdot x_2 + w_3$$

해석적 방법 : Least Squares Method (최소 제곱법)

✓ 최소 제곱법(Least Squares Method) 를 이용하여 회귀 계수를 결정

- m : 기울기
- c : 절편

$$m = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$c = \bar{y} - m\bar{x}$$

- x_i, y_i : 실제값
- $\bar{x}, \bar{y}$: 평균값
- $\hat{y}$: 예측값

모델링 절차

✓ 필요한 함수 불러오기

✓ 모델 선언

- 모델에 필요한 하이퍼 파라미터도 여기서 설정하게 됩니다.

✓ 학습

- .fit
- feature들과 target과의 관계, 패턴을 선형회귀 알고리즘을 이용하여 모델(함수)로 만듭니다.

알기 코드



▼ 31. import

```
[ ] 1 # multivariate regression을 해보자!  
    2 from sklearn.linear_model import LinearRegression  
    3 from sklearn.metrics import mean_squared_error, r2_score
```

▼ 32. 모델선언

```
[ ] 1 # 모델 선언  
    2 multi_regression = LinearRegression()
```

▼ 33. 모델링(학습)

```
[ ] 1 multi_regression.fit(train_features, train_target )
```

모델 내부 열어 보기

✓ 모델 열어 보기 :

- 모델.coef_ : 회귀계수
- 모델.intercept_ : Y절편

```
1 # 회귀계수 살펴보기. 모델을 열어 보자
2 a = simple_regression.coef_
3 b = simple_regression.intercept_
4
5 print(type(a))
6 print(a, b)
```

```
<class 'numpy.ndarray'>
[4.10813984] -19.75648317244979
```

✓ 이를 직선식으로 적어보면

$$y = 4.108 \cdot x - 19.756$$



예측 및 검증 평가

$\text{mean_absolute_error}(y_{\text{val}}, \text{pred})$

✓ 예측

- 학습시킨 모델이 얼마나 정확한지 검증하기 위해
- 학습할 때 사용하지 않은 데이터셋

```
1 # 예측값을 뽑자.  
2 test_pred = multi_regression.predict(test_features)
```

✓ 평가

- 회귀 모델은 평균오차의 양과 율로 평가합니다

```
1 # Training & Validation set에서의 성능 확인  
2  
3 print("MSE : {:.5f}".format(mean_squared_error(test_target, test_pred)))  
4 print("R-squared Score : {:.5f}".format(r2_score(test_target, test_pred)))
```


모델 평가

✓ 회귀 모델은 두 가지 관점으로 평가합니다.

1

[y 의 평균] 모델의 오차
VS
[회귀] 모델의 오차

R^2 Score

오차의 비
설명력
결정계수

2

[실제 값(y)]
VS
[예측 값($\hat{y}$)] 차이


MSE
RMSE
MAE
MAPE

오차의 양
오차의 비율

(1) 오차의 비로 평가하기 : R^2

✓ 평균 모델의 오차와 회귀모델 오차 : R^2


- ① 평균 모델과 실제 값 과의 차이(SST)
- ② 평균 모델과 회귀모델 과의 차이(SSR)
- ③ 실제 값과 회귀모델 과의 차이(SSE)



(1) 오차의 비로 평가하기 : R^2

✓ R-squared

- 평균 모델의 오차 대비 회귀모델이 해결한 오차의 비율
- 회귀모델이 얼마나 오차를 해결(설명)했는지를 나타냅니다.
- 결정계수, 설명력 이라고 부르기도 합니다.



$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

(2) 오차의 양과 율로 평가하기

오차의 크기

		Error	Squared Error	Absolute Error	
y	$\hat{y}$	$y - \hat{y}$	$(y - \hat{y})^2$	$ y - \hat{y} $	$\left \frac{y - \hat{y}}{y} \right $
6	4	2	4	2	1/3
5	6	-1	1	1	1/5
12	9	3	9	3	1/4
2	2	0	0	0	0

$$\frac{\sum}{n} \Rightarrow \text{mean}$$

Mean
Squared Error

Root Mean
Squared Error

Mean
Absolute Error

Mean Absolute
Percentage Error

MAPE [%
비율

(2) 오차의 양과 율로 평가하기

y	$\hat{y}$	$y - \hat{y}$	$(y - \hat{y})^2$	$ y - \hat{y} $
6	4	2	4	2
5	6	-1	1	1
12	9	3	9	3
2	2	0	0	0

$$\text{Sum Squared Error} = \sum (y - \hat{y})^2 = 14$$

$$\text{Mean SSE} = \frac{\sum (y - \hat{y})^2}{n} = \frac{14}{4}$$

$$\text{Root MSE} = \sqrt{\frac{\sum (y - \hat{y})^2}{n}} = \sqrt{\frac{14}{4}}$$

$$\text{Mean Absolute Err} = \frac{\sum |y - \hat{y}|}{n} = \frac{8}{4}$$

$$\text{Mean Absolute Percentage Err} = \frac{\sum \left| \frac{y - \hat{y}}{y} \right|}{n} =$$

요약 | Summary

✓ 선형회귀

- ① 알고리즘의 원리, 개념
→ 선형회귀식(직선,평면...)으로 Target과의 관계를 설명 합니다.
- ② 전제조건
→ 결측치 조치, 가변수화, feature들은 독립성 가정을 충족해야 합니다.
- ③ 성능 : hyper parameter, 복잡도 결정 요인
→ 변수가 많을 수록 복잡해 집니다.

✓ 회귀모델 평가

- 오차 해결 율 : R-squared(평균모델 오차 대비, 회귀모델이 해결한 비율)
- 오차의 양 : MSE, RMSE (오차 제곱의 평균), MAE(절대값 오차의 평균, 평균오차)
- 오차 율 : MAPE (오차율의 평균)