

# 데이터 분석 모델링

---

한 기 영

(주)데이터인사이트 대표

---

## 14. 로지스틱 회귀

# Logistic Regression

## ✓ 예를 들어



- 만약 오른쪽 회귀식이,  $f(x) = 0.7 \cdot x - 0.2$  라면...
- $f(x)$  의 범위는  $-\infty \sim \infty$  이다.
- 그러나 실제  $Y$ 는 0과 1입니다.

## ✓ 우리의 바램은...

- $X$ 가 커질수록  $f(x)$  는  $\infty$  가 아닌 1에 가까워지고,
- $X$ 가 작아질수록  $f(x)$  는 0에 가까워 지기를!

## ✓ 그래서 값을 변환할 필요가 있습니다.

- $-\infty \sim \infty \rightarrow 0 \sim 1$




# [참조]로지스틱 회귀분석 : 수학적식

## ✓ 로지스틱 함수

$$\overset{\text{로그 승산}}{\log \left( \frac{p_+(\mathbf{x})}{1 - p_+(\mathbf{x})} \right)} = \overset{\text{선형 판별식}}{f(\mathbf{x})} = w_0 + w_1x_1 + w_2x_2 + \dots$$

$$p_+(\mathbf{x}) = \frac{1}{1 + e^{-f(\mathbf{x})}}$$



# 로지스틱 회귀 모델

```
▶ 1 # 회귀계수 살펴보기. 모델을 열어 보자
2 print(X.columns.tolist())
3 print(model.coef_)          # 회귀계수
4 print(model.intercept_)     # y절편
```

```
☞ ['Age', 'SibSp', 'Parch', 'Fare', 'Pclass_2', 'Pclass_3', 'Sex_male', 'Embarked_Q', 'Embarked_S']
[[-1.94456439 -1.36000251 -0.20993713  0.37855165 -0.68617935 -1.8024144
  -2.52773213 -0.10234921 -0.53627272]]
[3.38144521]
```

$$f(x) = -1.94 \cdot Age - 1.36 \cdot SibSp - 0.21 \cdot Parch + 0.37 \cdot Pclass_3 + \dots$$

$$p_+(\mathbf{x}) = \frac{1}{1 + e^{-f(\mathbf{x})}}$$

# [참조] 회귀 계수 해석하기

$$f(x) = -1.94 \cdot Age - 1.36 \cdot SibSp - 0.21 \cdot Parch + 0.37 \cdot Fare + \dots$$

$$p_+(x) = \frac{1}{1 + e^{-f(x)}}$$

✓ 값이 증가할 때 아래 값들은 어떻게 변할까요?

|      | coefficient | $f(x)$ | $e^{-f(x)}$ | $P(x)$ |
|------|-------------|--------|-------------|--------|
| Age  | -1.94       |        |             |        |
| Fare | 0.37        |        |             |        |

# 분류문제 평가 : Confusion Matrix

## ✓ 일반적으로 이진 분류일때,

- 우리의 관심사 = 1, 양성 Positive
- 그 외 = 0, 음성 Negative

| COVID 19 |    | 진단 결과          |                |
|----------|----|----------------|----------------|
|          |    | 양성(Positive)   | 음성(Negative)   |
| 실제 감염여부  | 감염 | True Positive  | False Negative |
|          | 정상 | False Positive | True Negative  |

✓ 정분류율, 정확도(Accuracy) =  $\frac{(TP+TN)}{Total} \times 100$

✓ 민감도(Sensitivity), 재현율(Recall) =  $\frac{TP}{(TP+FN)} \times 100$  (실제 독감에 감염된 자들 중 양성이라고 맞춘 비율)

✓ 정밀도(Precision) =  $\frac{TP}{(TP+FP)} \times 100$  (양성이라고 예측한 자들 중 실제 양성인(맞춘) 비율)

# 분류문제 평가 : Confusion Matrix

✓ 직접 계산해 봅시다.

```
1 # confusion matrix
2 print(confusion_matrix(val_y, val_pred))
```

[[80 11]  
[19 33]]

| 생존여부 |    | 예측 |    |
|------|----|----|----|
|      |    | 사망 | 생존 |
| 실제   | 사망 | 80 | 11 |
|      | 생존 | 19 | 33 |

- 정분류율, 정확도(Accuracy) =
- 민감도(Sensitivity), 재현율(Recall) =
- 정밀도(Precision) =

# 분류문제 평가 : classification report

```
1 # confusion matrix
2 print(confusion_matrix(val_y, val_pred))
```

[[80 11]  
[19 33]]

```
1 # classification report
2 print(classification_report(val_y, val_pred))
```

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.81      | 0.88   | 0.84     | 91      |
| 1            | 0.75      | 0.63   | 0.69     | 52      |
| accuracy     |           |        | 0.79     | 143     |
| macro avg    | 0.78      | 0.76   | 0.76     | 143     |
| weighted avg | 0.79      | 0.79   | 0.79     | 143     |

## ✓ f1-score

- precision과 recall의 조화 평균,
- 예) 갈 때 60km/h, 올 때 80km/h로 주행했을 때, 평균 속력은?
- 수식 : 역수의 산술평균의 역수 =  $\frac{2}{\frac{1}{\text{precision}} + \frac{1}{\text{recall}}}$

✓ macro avg : 산술평균

✓ weighted avg : 가중평균

✓ support : 데이터 개수

# 평가지표 : f1-Score

✓ 정밀도와 재현율의 조화 평균


✓ 조화평균 : 두 숫자의 역수의 산술평균의 역수

- 분자가 같지만 분모가 다를 경우 조화평균 사용(예, 갈 때 속도 100km/h , 올 때 속도 60km/h, 평균속력?)

$$\frac{2}{\frac{1}{prec} + \frac{1}{rec}} = \frac{2 \cdot prec \cdot rec}{prec + rec}$$

$$\frac{a+b}{2} \geq \sqrt{ab} \geq \frac{2ab}{a+b}$$

산술평균      기하평균      조화평균



# 요약 | Summary

## ✓ 로지스틱 회귀

- ① 알고리즘의 원리, 개념
  - ➔ 선형 판별식을 찾고(선형회귀분석과 동일), 선형 판별식으로 부터의 거리를 0~1로 변환
- ② 전제조건
  - ➔ NaN 조치, 가변수화, feature들 간의 독립
- ③ 성능 : hyper parameter, 복잡도 결정 요인
  - ➔ 어떤 변수를 포함할 것인가?, 변수 선택이 중요. 변수가 많을 수록 복잡해 집니다.

# 요약 | Summary

## ✓ 분류모델의 평가

- 실 제값과 예측 값에 대한 교차표(confusion matrix)를 만들고
- 이것으로 부터 성능지표 계산

## ✓ 성능지표

- 전체 관점
  - Accuracy 정 분류율 : 전체 중에서 맞춘 비율
- 특정 class 관점
  - Recall 재현율 : 실제 해당 class 중에서 맞춘 비율
  - Precision 정밀도 : 해당 class라고 예측한 것 중 맞춘 비율
  - F1 Score : Recall과 Precision의 조화평균