

데이터 분석 입문반



한 기 영

(주)데이터인사이트

기본 알고리즘 4. 최근접 이웃(KNN)

KNN (k -Nearest Neighbor)

- 1) 예측해야 할 데이터와 주어진 데이터의 모든 거리를 계산
- 2) 가까운 거리의 데이터를 K 개 만큼 찾은 후
- 3) K 개 값의 평균을 계산하여 예측(k 개 값의 class를 보고 예측)



KNN (k -Nearest Neighbor)

✓ 장점

- 데이터의 분포 형태와 상관이 없습니다.
- 설명변수의 개수가 많아도 무리 없이 사용 가능 합니다.


✓ 단점

- 계산시간이 오래 걸립니다.
- 훈련데이터를 모델에 함께 저장 합니다.
- 해석하기 어렵습니다.

KNN (k -Nearest Neighbor)

✓ K값 결정


- K에 따라서 예측 결과가 달라집니다.
 - $K = 3$
 - $K = 6$
- k 값을 최대로 키우려면
 - 얼마까지?
 - K 값이 최대값일 때 예측 결과는?
- K 값이 1이면
 - 어떻게 예측 하게 될까요?




KNN (k -Nearest Neighbor)

✓ 거리 계산법에 따라 성능이 달라질 수 있습니다.

Euclidean Distance




Manhattan Distance



KNN을 위한 전처리 : Scaling

✓ 스케일링이란?

- Feature들 값의 범위와 단위가 각각 다르기 때문에
- 값의 범위가 큰 Feature일 수록 거리 계산에 영향을 많이 줍니다.
- 그런 변수가 더 중요하게 여겨질 수 있습니다.
- 그러므로 모든 값의 범위를 맞춰 주는 것이 스케일링!



KNN을 위한 전처리 : Scaling

✓ 값의 범위를 맞춰 주기 위해서 변수

✓ 방법 1 : Normalization

- 입력변수 X 가 $[a, b]$ 범위라면($a=\min, b=\max$)

$$X_{norm} = \frac{x - a}{b - a}$$

✓ 방법2 : Standardization

$$X_z = \frac{x - mean}{std}$$

| 복습


전체 Process(CRISP-DM)

무엇이 문제인가?

- ✓ 비즈니스 문제정의
- ✓ 데이터분석 방향, 목표
- ✓ 초기 가설 수립

$x \rightarrow y$

- ✓ 모델 관리
- ✓ AI 서비스 구축



- ✓ 원본식별
- ✓ 분석을 위한 구조 만들기
- ✓ 데이터분석 EDA & CDA

- ✓ 모델링을 위한 데이터 구조 만들기
 - 모든 셀은 값이 있어야 한다.
 - 모든 값은 숫자 여야 한다.
 - (필요 시) 숫자의 범위가 일치

- ✓ 모델을 만들고
- ✓ 검증하기

문제가 해결 되었는가?

- ✓ 기술적 관점 평가
- ✓ 비즈니스 관점 평가

데이터 분석

✓ 단변량 분석

	기초 통계량	시각화
숫자형 양적 데이터 (정량적 데이터)	min, max, mean, std, 사분위수	Histogram Density plot Box plot
범주형 질적 데이터 (정성적 데이터)	범주별 빈도수 범주별 비율	Bar plot (Pie chart)

✓ 이변량 분석

		y	
		숫자형	범주형
X	숫자형	관점 : 직선의 관계 산점도, 상관분석	범주별 kde plot
	범주형	관점 : 평균 비교 평균비교 막대그래프(sns.bar) 범주2개 - t검정, 범주3개~ - 분산분석	관점 : 기대빈도와 실제빈도 차이 모자익플롯, 카이제곱검정

머신러닝 코드 구조

데이터 전처리

불필요한 변수 제거

NaN 조치

데이터 분할1 : X, y

가변수화

데이터 분할2 : train, val

스케일링

모델링

① 모델 선언

모델 준비 하기 : 모델에 대한 설정

② 학습

모델 만들기 : 학습 데이터를 이용해서 모델링

③ 예측(검증)

모델 사용하기 : 검증 데이터로 예측

④ 평가(검증)

모델 평가하기 : 예측 결과 점수 계산

선형회귀(Linear Regression)

✓ ① 알고리즘의 원리, 개념

- → 선형회귀식(직선,평면...)으로 Target과의 관계를 설명

✓ ② 전제조건

- → NaN 조치, 가변수화, feature들은 독립성 가정을 충족해야 함.

✓ ③ 성능 : hyper parameter, 복잡도 결정 요인

- → 어떤 변수를 포함할 것인가? 변수 선택이 중요.
→ 변수가 많을 수록 복잡해짐.

로지스틱 회귀(Logistic Regression)

✓ ① 알고리즘의 원리, 개념

→ 선형 판별식을 찾고(선형회귀모델과 동일), 로지스틱함수(시그모이드)를 이용하여 0 ~ 1 사이 확률값으로 변환

✓ ② 전제조건

▪ → NaN 조치, 가변수화, feature들 간의 독립

✓ ③ 성능 : hyper parameter, 복잡도 결정 요인

▪ → 어떤 변수를 포함할 것인가?, 변수 선택이 중요. 변수가 많을 수록 복잡해짐

의사결정 나무(Decision Tree)

✓ ① 알고리즘의 원리, 개념

- → 정보 전달량이 가장 높은 변수와 기준으로 split

✓ ② 전제조건

- → NaN 조치, 가변수화

✓ ③ 성능 : hyper parameter, 복잡도 결정 요인

- → max_depth : 클수록 모델이 복잡
- → min_samples_leaf : 작을수록 모델이 복잡

KNN

✓ ① 알고리즘의 원리, 개념

- → 가까운 거리의 데이터(이웃)의 Y를 보고 판단

✓ ② 전제조건

- → NaN 조치, 가변수화, 스케일링!

✓ ③ 성능 : hyper parameter, 복잡도 결정 요인

- → k : 가까운 거리의 이웃 수
- → metric : 거리계산 방식(Euclidean, Manhattan)

모델 평가

✓ 회귀모델 평가

- MSE, RMSE (오차 제곱의 평균), MAE(절대값 오차의 평균, 평균 오차)
- MAPE (오차율의 평균)
- R-squared(평균모델 오차 대비, 회귀모델이 해결한 비율)

✓ 분류모델의 평가

- 실 제값과 예측 값에 대한 교차표(confusion matrix)를 만들고, 성능지표 계산
- 전체 관점 : Accuracy 정분류율
- 특정 class 관점
 - Recall 재현율 : 실제 해당 class 중에서 맞춘 비율
 - Precision 정밀도 : 해당 class라고 예측한 것 중 맞춘 비율
 - F1 Score : Recall과 Precision의 조화평균